

《人工智能导论》大作业报告

任务名称：可解释的谣言检测
完成组号：5
小组成员：施佳瑜（组长）、邹佳怡、陶泽镐
完成时间：2026年6月

1. 任务目标

本项目面向社交媒体英文短文本，输入一条推文，输出谣言检测标签和文字判断依据。其中 0 表示非谣言，1 表示谣言。我们希望在课程数据集上取得较高准确率，同时控制训练和推理时间，并保证代码、模型及配置可以复现。

2. 具体内容

2.1 实施方案

小组分工

我们小组的分工如下：

- 施佳瑜**：担任组长，负责分类模型实现、参数调优、模型融合、报告完善。具体工作包括完成文本预处理流程，比较多种模型方案在不同参数、权重下的验证集结果，最终确定TF-IDF、BERTweet、MPNet加权融合方案；完善实验报告。贡献比例为 33.3%。
- 邹佳怡**：主要负责模型解释和大语言模型接入部分。具体工作包括设计判断依据的输出形式，编写提示词，使大模型只能根据已有模型证据生成解释，不能重新分类或编造事实；接入学校提供的deepseek-chat接口。贡献比例为 33.3%。
- 陶泽镐**：主要参与报告整理并协助调优过程。具体工作包括尝试使用BERT进行模型训练；协助整理报告内容，复现实验。贡献比例为 33.3%。

实验流程

预处理时先进行 HTML 转义还原和小写化，再将网址、用户提及分别替换为固定标记。这样既能减少文本噪声，又能保留链接和提及行为本身可能包含的判别信息。词级特征进一步去除无关标点，字符级特征保留局部拼写模式。

实验阶段共测试了 274 种模型、参数、阈值和融合组合。代表性结果如下：

模型	val.csv 准确率
Word TF-IDF + LogisticRegression	0.8279
Word/Char TF-IDF + LinearSVC	0.8728
BERTweet + LinearSVC	0.8379
MPNet + LogisticRegression	0.8404
最终加权融合模型	0.8953

实验先比较 TF-IDF、逻辑回归和 LinearSVC 等传统模型，再尝试 BERTweet、MPNet。由于小规模数据上直接微调收益有限，最终采用预训练特征加轻量分类器的方案。

最终模型由三部分组成：3 个 Word/Char TF-IDF + LinearSVC 的平均结果占 0.60，BERTweet 语义特征 + LinearSVC 占 0.20，MPNet 句向量 + LogisticRegression 占 0.20。TF-IDF 主要捕捉关键词、短语和局部拼写模式；BERTweet 针对推文语言训练，适合处理社交媒体表达；MPNet 提供较通用的句子语义表示。三者关注的信息不同，因此具有一定互补性。

各组件分数先用训练集统计量做 Z-score 标准化，再加权求和，并以固定阈值 0.03 分类。随机种子固定为 42，嵌入结果和最终模型均保存到本地，便于重复运行和检查结果。

2.2 核心代码分析

`preprocessing.py` 中的 `load_dataset` 检查必需字段、空值和二分类标签；`normalize_tweet` 统一处理 HTML、网址、用户提及和大小写，`clean_for_word` 再生成适合词级 TF-IDF 的文本。


`models.py` 是分类部分的核心。训练时，三个 TF-IDF 子模型分别构造词 1~2 gram 和字符 3~5 gram 特征，并使用不同的 C 值和停用词设置训练 LinearSVC，标准化分数后取平均。BERTweet 对所有 token 隐藏状态进行掩码均值池化，MPNet 生成归一化句向量，随后分别训练 LinearSVC 和 LogisticRegression。`score_models` 读取三个组件的分数，按照配置文件中的权重完成标准化融合。

`train.py` 固定随机种子并调用上述训练流程，最后用 Joblib 保存模型、分类器和标准化参数。`evaluate.py` 加载同一模型，在 `val.csv` 上统一计算 Accuracy、Precision、Recall、F1 和混淆矩阵。`predict.py` 则把分类与解释整合为单条文本入口：先得到标签和各组件贡献，再由 `explanation.py` 提取关键词证据，最后调用 `llm_explainer.py` 生成说明；若接口失败，则返回本地解释。

2.3 检测结果分析

最终模型在 `val.csv` 上预测正确 359 条，总体准确率为 0.8953。各类别及总体结果如下：

类别	Precision	Recall	F1	样本数
非谣言	0.8898	0.9292	0.9091	226
谣言	0.9030	0.8514	0.8765	175
总体（加权平均）	0.8956	0.8953	0.8949	401



混淆矩阵中，210 条非谣言和 149 条谣言被正确识别，误报 16 条，漏检 26 条。谣言类别的 Precision 为 0.9030，说明被判为谣言的样本大多正确；Recall 为 0.8514，仍有部分谣言没有检出。

2.4 判断依据分析

分类结果完全由本地融合模型给出，大语言模型不参与标签判定。系统先根据 TF-IDF 值和线性分类器系数计算关键词贡献，再给出三个子模型分别支持谣言或非谣言的方向及强度，最后将这些结构化证据交给学校接口中的 `deepseek-chat`，生成 2 至 4 句中文解释。

提示词明确限制大模型不得修改标签、虚构事实或声称已经完成外部事实核查。相同文本的解释会写入缓存；接口未配置、网络异常或请求失败时，程序自动改用本地模板解释，因此分类功能不会受大模型接口影响。该解释反映模型学到的语言模式，不能替代真实新闻核验。

模型检测及大语言模型解释示例：

```
PS C:\Users\21249\Desktop\作业\机器学习\实验七> python src/predict.py --show-source "Is Prince playing a surprise show at Massey Hall tonight? http://t.co/mv0Ca9ro6a"
检测结果：1（谣言）
判断依据：该文本被判定为谣言，因为内容声称Prince将在Massey Hall举行惊喜演出，但各分析组件均一致支持谣言判断。核心短语如“prince”和“massey hall”与常见谣言模式高度相关，而链接的使用进一步暗示了诱导性传播。尽管文本表面像是正常活动通知，但多个语义模型均识别出其缺乏可信框架，整体证据较强地指向虚假信息。
解释来源：deepseek-chat
```

3. 工作总结

实验中主要遇到三个问题。第一，各模型输出尺度不同，直接相加会让数值较大的组件占主导，因此使用训练集均值和标准差统一尺度。第二，预训练模型编码耗时较长，因此加入 SHA-256 校验的嵌入缓存。第三，大模型接口可能受网络和调用频率影响，因此实现缓存、限速、重试和本地降级。

实验表明，在小规模短文本上，TF-IDF 仍是稳定有效的特征，BERTweet 和 MPNet 则为融合模型补充语义信息。我们认识到模型并非越复杂越好，还需综合考虑数据规模、运行成本、可复现性和解释能力。整个过程加深了我们对实验设计、模型评价和工程实现的理解。

4. 课程建议

建议课程可以增加模型融合、预训练模型特征提取和大模型接口工程实践的示例，并说明分类解释与事实核查之间的区别，帮助我们更完整地理解可解释人工智能系统。