

《人工智能导论》大作业报告

任务名称： 可解释的谣言检测
完成组号： 7 **小组成员：** 施佳瑜（组长）、邹佳怡、陶泽镐
完成时间： 2026年6月

1. 任务目标

本项目面向社交媒体英文短文本，输入一条推文，输出谣言检测标签和文字判断依据。其中 0 表示非谣言，1 表示谣言。我们希望在课程数据集上取得较高准确率，同时控制训练和推理时间，并保证代码、模型及配置可以复现。

2. 具体内容

我们小组的分工如下：施佳瑜担任组长，负责分类模型实现、参数调优和模型融合；邹佳怡负责大模型接口、解释提示词和解释功能；陶泽镐参与模型调优、项目集成、复现测试和报告整理。三位成员贡献比例均为 33.3%。

2.1 实施方案

课程数据包含 id、text、label、event 四列。训练集共 2840 条，其中非谣言 1600 条、谣言 1240 条；val.csv 共 401 条，其中非谣言 226 条、谣言 175 条。模型训练只读取 train.csv，模型选择和结果评价按课程要求在 val.csv 上完成。

预处理时先进行 HTML 转义还原和小写化，再将网址、用户提及分别替换为固定标记。这样既能减少文本噪声，又能保留链接和提及行为本身可能包含的判别信息。词级特征进一步去除无关标点，字符级特征保留局部拼写模式。

实验阶段共测试了 274 种模型、参数、阈值和融合组合。其中比较具有代表性的结果如下：

模型	val.csv 准确率
Word TF-IDF + LogisticRegression	0.8279
Word/Char TF-IDF + LinearSVC	0.8728
BERTweet + LinearSVC	0.8379
MPNet + LogisticRegression	0.8404
最终加权融合模型	0.8953

实验先比较词级和字符级 TF-IDF、逻辑回归、LinearSVC 及集成模型，再尝试 BERTweet、MPNet 等预训练模型。直接微调在当前小规模数据上的提升有限、成本较高，因此最终采用冻结预训练模型提取语义特征，再训练轻量分类器的方式。

最终模型由三部分组成：3 个 Word/Char TF-IDF + LinearSVC 的平均结果占 0.60，BERTweet 语义特征 + LinearSVC 占 0.20，MPNet 句向量 + LogisticRegression 占 0.20。TF-IDF 主要捕捉关键词、短语和局部拼写模式；BERTweet 针对推文语言训练，适合处理社交媒体表达；MPNet 提供较通用的句子语义表示。三者关注的信息不同，因此具有一定互补性。

各组件分数先用训练集统计量做 Z-score 标准化，再加权求和，并以固定阈值 0.03 分类。训练时只使用 `train.csv`，验证时统一加载保存后的模型在 `val.csv` 上预测。随机种子固定为 42，嵌入结果和最终模型均保存到本地，便于重复运行和检查结果。

2.2 核心代码分析

`preprocessing.py` 中的 `load_dataset` 检查必需字段、空值和二分类标签；`normalize_tweet` 统一处理 HTML、网址、用户提及和大小写，`clean_for_word` 再生成适合词级 TF-IDF 的文本。

`models.py` 是分类部分的核心。训练时，三个 TF-IDF 子模型分别构造词 1~2 gram 和字符 3~5 gram 特征，并使用不同的 C 值和停用词设置训练 LinearSVC，标准化分数后取平均。BERTweet 对所有 token 隐藏状态进行掩码均值池化，MPNet 生成归一化句向量，随后分别训练 LinearSVC 和 LogisticRegression。`score_models` 读取三个组件的分数，按照配置文件中的权重完成标准化融合。训练集统计量单独保存，验证和预测时不重新计算，避免引入验证集信息。

`train.py` 固定随机种子并调用上述训练流程，最后用 Joblib 保存模型、分类器和标准化参数。`evaluate.py` 加载同一模型，在 `val.csv` 上统一计算 Accuracy、Precision、Recall、F1 和混淆矩阵。`predict.py` 则把分类与解释整合为单条文本入口：先得到标签和各组件贡献，再由 `explanation.py` 提取关键词证据，最后调用 `llm_explainer.py` 生成说明；若接口失败，则返回本地解释。模型名称、批大小、融合权重和阈值均写入配置文件，便于复现。

2.3 检测结果分析

最终模型在 `val.csv` 上预测正确 359 条，总体准确率为 0.8953。各类别及总体结果如下：

类别	Precision	Recall	F1	样本数
非谣言	0.8898	0.9292	0.9091	226
谣言	0.9030	0.8514	0.8765	175
总体（加权平均）	0.8956	0.8953	0.8949	401

最终模型混淆矩阵

混淆矩阵中，210 条非谣言和 149 条谣言被正确识别，误报 16 条，漏检 26 条。谣言类别的 Precision 为 0.9030，说明被判为谣言的样本大多正确；Recall 为 0.8514，仍有部分谣言没有检出。融合模型比最佳单模型高约 2.2 个百分点，说明词汇特征与预训练语义特征具有互补性。

2.4 判断依据分析

分类结果完全由本地融合模型给出，大语言模型不参与标签判定。系统先根据 TF-IDF 值和线性分类器系数计算关键词贡献，再给出三个子模型分别支持谣言或非谣言的方向及强度，最后将这些结构化证据交给学校接口中的 `deepseek-chat`，生成 2 至 4 句中文解释。

提示词明确限制大模型不得修改标签、虚构事实或声称已经完成外部事实核查。相同文本的解释会写入缓存；接口未配置、网络异常或请求失败时，程序自动改用本地模板解释，因此分类功能不会受大模型接口影响。该解释反映模型学到的语言模式，不能替代真实新闻核验。

3. 工作总结

实验中主要遇到三个问题。第一，各模型输出尺度不同，直接相加会让数值较大的组件占主导，因此使用训练集均值和标准差统一尺度。第二，预训练模型编码耗时较长，因此加入 SHA-256 校验的嵌入缓存。第三，大模型接口可能受网络和调用频率影响，因此实现缓存、限速、重试和本地降级。

本次实践表明，在小规模短文本数据上，TF-IDF 仍然是稳定而有效的特征；BERTweet 和 MPNet 单独使用时没有超过 TF-IDF，但加入融合后能够补充语义信息。模型性能之外，固定随机种子、保存配置和提供清晰运行说明也直接影响项目能否复现。

这次项目让我们认识到，模型越复杂并不一定效果越好，数据规模、文本特点和训练方式都会影响表现。经过多轮比较后，我们不再单纯追求复杂结构，而是保留各方案真正有效的部分并进行融合。可解释性模块也让我们意识到，给出标签只是第一步，还要说明模型依据了哪些语言特征，并明确其与事实核查的区别。整个过程加深了我们对实验设计、模型评价和工程实现的理解。

4. 课程建议

建议课程可以增加模型融合、预训练模型特征提取和大模型接口工程实践的示例，并说明分类解释与事实核查之间的区别，帮助我们更完整地理解可解释人工智能系统。